

Резюме 01_eda_data.ipynb

EDA датасета Give Me Some Credit: качество данных, целевой класс, выбросы и риск-маркеры.

Коротко

- Ноутбук делает первичный EDA raw-датасета Give Me Some Credit: переименовывает поля, проверяет качество, изучает пропуски, выбросы, целевой класс и связи признаков с дефолтом.
- Базовый bad rate после удаления дублей - около 6.70%. Класс сильно несбалансирован, поэтому ассигасу не подходит как главная метрика.
- Главные полезные сигналы для feature engineering - прошлые просрочки, диапазон revolving_utilization 0.5-10.0, отдельные диапазоны debt_ratio, возраст и нулевое число открытых кредитных линий.

Данные и качество

Пункт	Значение	Комментарий
Источник	data/raw/cs-training.csv	Целевая переменная - факт просрочки 90+ дней в следующие 2 года.
Raw-размер	150,000 строк x 11 колонок	Индексная колонка Unnamed: 0 удаляется.
Дубли	609 строк, 0.406%	После drop_duplicates остается 149,391 строка.
Bad rate	6.70%	После удаления дублей: 10,009 bad из 149,391; Wilson CI примерно 6.57%-6.83%.
Пропуски	monthly_income: 29,221 (19.56%); num_dependents: 3,828 (2.56%)	Пропуски важны сами по себе и дальше превращаются в индикаторы.
Особенность дублей	Bad rate 3.33%	В дублях много пропусков дохода (84.6%), поэтому они похожи на технические или шаблонные записи.

Главные EDA-находки

Признак	Что видно в EDA	Что делать дальше
revolving_utilization	Связь с target сильная и нелинейная. Диапазоны 0.5-5.0 дают заметно повышенный bad rate; очень дальний хвост >1000% почти не усиливает сигнал.	Клиппинг верхнего хвоста, дискретизация и маркер rev_ut [0.5, 10.0].
age	В среднем чем старше заемщик, тем ниже риск. Маркер age [18, 52] сам по себе слабее просрочек.	Оставить как числовой признак и использовать только в отдельных комбинациях.
num_30_59_days_late, num_60_89_days_late, num_90_days_late	Все признаки прошлых просрочек имеют сильную нелинейную связь с будущим дефолтом.	Добавить бинарные маркеры > 0 и комбинации просрочек.
debt_ratio	Диапазон 0.5-3.0 выглядит рискованнее. Очень большие значения часто ведут себя как абсолютные суммы, а не как отношение.	Клиппинг, лог-преобразование, бины и маркер d_r [0.5, 3.0].
monthly_income	Есть много пропусков; низкий/средний доход полезен в комбинациях.	Добавить missing-flag, заполнить пропуски -1, использовать log и бины.
num_open_credit_lines	Значение 0 при ненулевой утилизации выглядит как отдельный риск-сигнал.	Добавить маркер c_lines = 0.

Маркеры-кандидаты из EDA

Маркер	Охват	Оценка эффекта в EDA
rev_ut [0.5, 10.0]	около 40.7k строк	Прирост bad rate около 10.27 п.п.
30_59 > 0	около 23.9k строк	Прирост около 13.71 п.п.
60_89 > 0	около 7.6k строк	Прирост около 28.85 п.п.

Маркер	Охват	Оценка эффекта в EDA
90 > 0	около 8.3k строк	Прирост около 34.17 п.п.
c_lines = 0	около 1.7k строк	Прирост около 18.70 п.п.

Важно: ноутбук прямо помечает маркеры как гипотезы. Их надо проверять на validation/test, потому что они подобраны по обучающей выборке.

Итог для проекта

- EDA дал набор понятных риск-маркеров, которые затем были перенесены в feature_engineering.py.
- Перед моделированием данные нужно очистить от дублей, кодировать пропуски дохода и иждивенцев, а экстремальные значения revolving_utilization и debt_ratio обрабатывать отдельно.
- Для оценки моделей стоит ориентироваться на ROC-AUC, Average Precision, Recall и Precision, а не на ассурасу, из-за сильного дисбаланса классов.