

Резюме 02_feature_engineering.ipynb

Feature engineering: пространство признаков, выбранные преобразования, маркеры и DVC-датасеты.

Коротко

- Ноутбук проверяет пространство признаков, выбранные преобразования и маркеры, после чего сверяет готовые DVC-датасеты для линейных и древесных моделей.
- Общий кандидатный feature space содержит 126 колонок: исходные признаки, log-варианты, дискретизированные dummy-признаки, always-on флаги и EDA-маркеры.
- Финальные датасеты разделены по семействам моделей: linear - 57 признаков, tree - 22 признака.

Вход и общий feature space

Пункт	Значение
Вход	data/interim/train_prepared.csv
Prepared train	149,390 строк x 13 колонок
Общий feature space	149,390 строк x 126 колонок
Always-on признаки	7
Dummy-признаки после дискретизации	83
EDA-маркеры	15
Комбинации преобразований	39,366
Комбинации маркеров	32,768, включая пустой набор

Always-on признаки

- monthly_income_is_nan, num_dependents_is_nan.
- revolving_utilization_gt_10, debt_ratio_gt_10.
- num_30_59_days_late_is_96_or_98, num_60_89_days_late_is_96_or_98, num_90_days_late_is_96_or_98.

Выбранные преобразования

Семейство	Выбранная схема	Финальный размер
linear	origin: age, num_90_days_late, num_dependents; log: debt_ratio, monthly_income, num_30_59_days_late, num_60_89_days_late; discretization: revolving_utilization, num_open_credit_lines, num_real_estate_loans.	train/test: 149,390 / 101,175 строк; 58 колонок с target, то есть 57 признаков.
tree	origin: все 10 базовых признаков; log: нет; discretization: нет.	train/test: 149,390 / 101,175 строк; 23 колонки с target, то есть 22 признака.

Выбранные маркеры

Семейство	Маркеры
linear	30_59 > 0; 60_89 > 0; 90 > 0; c_lines = 0; 30_59 > 0 + 60_89 > 0; 30_59 > 0 + 60_89 > 0 + d_r [0.5, 3.0]; 30_59 > 0 + 90 > 0; 60_89 > 0 + 90 > 0; rev_ut [0.5, 10.0] + 60_89 > 0 + d_r [0.5, 3.0]; age [18, 52] + 90 > 0 + d_r [0.5, 3.0]; rev_ut [0.5, 10.0] + 90 > 0 + d_r [0.5, 3.0].
tree	30_59 > 0; 60_89 > 0; 90 > 0; rev_ut [0.5, 10.0]; 30_59 > 0 + 60_89 > 0 + 90 > 0.

Охват маркеров

Маркер	Строк	Доля
rev_ut [0.5, 10.0]	40,746	27.27%
30_59 > 0	23,937	16.02%
90 > 0	8,283	5.54%
60_89 > 0	7,560	5.06%
30_59 > 0 + 60_89 > 0	4,349	2.91%
30_59 > 0 + 90 > 0	4,305	2.88%
60_89 > 0 + 90 > 0	2,749	1.84%
c_lines = 0	1,712	1.15%

DVC-выходы

Файл	Размер
data/processed/linear/train.csv	149,390 строк x 58 колонок
data/processed/linear/test.csv	101,175 строк x 58 колонок
data/processed/tree/train.csv	149,390 строк x 23 колонки
data/processed/tree/test.csv	101,175 строк x 23 колонки

Итог: notebook фиксирует выбранные признаки через проектный модуль, поэтому ручная проверка, DVC-пайплайн и обучение моделей используют один и тот же набор feature engineering решений.