

Резюме 03_train_models.ipynb

Обучение моделей: план подбора, сравнение качества, лучшие параметры и артефакты.

Коротко

- Ноутбук запускает подбор гиперпараметров для пяти моделей: Logistic Regression, Decision Tree, XGBoost, CatBoost и Random Forest.

- Критерий подбора - ROC-AUC на 5-fold Stratified CV; дополнительная проверка - holdout validation 20% при random_state=52.

- По validation ROC-AUC лидирует XGBoost (0.863794), по CV ROC-AUC немного впереди CatBoost (0.867065).

Входные датасеты

Датасет	Файл	Строк	Признаков	Target rate
linear	data/processed/linear/train.csv	149,390	57	6.70%
tree	data/processed/tree/train.csv	149,390	22	6.70%

План подбора

Модель	Датасет	Поиск	CV	n_iter / n_jobs
logistic_regression	linear	grid	5	n_jobs=-1
decision_tree	tree	grid	5	n_jobs=-1
xgboost	tree	random	5	n_iter=30, n_jobs=1
catboost	tree	random	5	n_iter=25, n_jobs=1
random_forest	tree	random	5	n_iter=20, n_jobs=1

Сравнение лучших моделей

Модель	CV ROC-AUC	Valid ROC-AUC	Avg Precision	Precision	Recall	F1
logistic_regression	0.861040	0.859239	0.388078	0.224511	0.745754	0.345123
decision_tree	0.854057	0.848535	0.368038	0.199488	0.778222	0.317570
xgboost	0.866852	0.863794	0.398633	0.214315	0.777722	0.336031
catboost	0.867065	0.863498	0.400310	0.217949	0.764236	0.339171
random_forest	0.864676	0.861058	0.392112	0.229199	0.740260	0.350024

Лучшие параметры

Модель	Параметры
logistic_regression	C=5.0, solver=liblinear
decision_tree	criterion=entropy, max_depth=7, min_samples_leaf=200, min_samples_split=50
xgboost	colsample_bytree=0.8, learning_rate=0.03, max_depth=4, n_estimators=400, reg_lambda=10.0, subsample=1.0
catboost	depth=6, iterations=700, l2_leaf_reg=10.0, learning_rate=0.03
random_forest	max_depth=12, max_features=sqrt, min_samples_leaf=20, n_estimators=500

Итоговая интерпретация

- Если выбирать строго по сортировке ноутбука (`valid_roc_auc`, затем `recall` и `precision`), первым идет XGBoost.
- CatBoost почти не уступает на holdout и имеет лучший CV ROC-AUC, поэтому выглядит как сильная альтернатива при повторных проверках.
- Random Forest показывает лучший F1 и `precision` среди сравниваемых моделей, но уступает XGBoost/CatBoost по ROC-AUC.
- Decision Tree дает самый высокий `recall`, но хуже по ROC-AUC и `precision`; его удобно держать как интерпретируемый baseline.

В ноутбуке `SAVE_ARTIFACTS=False`, но проектный DVC-пайплайн уже сохраняет модели в `models/*.joblib` и отчеты в `reports/modeling/*.json`, `*.csv`, `*.md`.