

Airflow в проекте

Give Me Some Credit - краткая проектная документация. Сформировано: 10.07.2026.

Назначение

Airflow используется для ручной оркестрации финального ML-пайплайна. DAG не реализует подготовку данных заново внутри Python-кода, а вызывает уже описанные DVC-стадии через `dvc repro`.

Где находится DAG

Параметр	Значение
Файл	<code>airflow/dags/train_optimal_models.py</code>
<code>dag_id</code>	<code>give_me_some_credit_train_optimal_models</code>
<code>schedule</code>	None, запуск вручную
<code>catchup</code>	False
<code>max_active_runs</code>	1
<code>tags</code>	<code>credit-risk, training, dvc</code>

Логика задач

DAG сначала пересобирает feature-engineering датасеты, затем параллельно запускает обучение моделей.

Task	DVC stage
<code>build_feature_datasets</code>	<code>dvc repro build-feature-engineering-datasets</code>
<code>train_logistic_regression</code>	<code>dvc repro train-logistic-regression</code>
<code>train_decision_tree</code>	<code>dvc repro train-decision-tree</code>
<code>train_xgboost</code>	<code>dvc repro train-xgboost</code>
<code>train_catboost</code>	<code>dvc repro train-catboost</code>
<code>train_random_forest</code>	<code>dvc repro train-random-forest</code>

Переменные окружения

Переменная	Значение по умолчанию	Зачем нужна
<code>GIVE_ME_SOME_CREDIT_PROJECT_ROOT</code>	<code>/opt/airflow/give_me_some_credit</code>	Путь к смонтированному репозиторию внутри Airflow.
<code>GIVE_ME_SOME_CREDIT_DVC_REPRO_CMD</code>	<code>dvc repro</code>	Команда запуска DVC. Можно заменить на <code>poetry run dvc repro</code> .

Как запускать

```
export GIVE_ME_SOME_CREDIT_PROJECT_ROOT=/opt/airflow/give_me_some_credit
export GIVE_ME_SOME_CREDIT_DVC_REPRO_CMD='poetry run dvc repro'
# затем в Airflow UI запустить DAG give_me_some_credit_train_optimal_models
```

Перед запуском DAG в окружении Airflow должны быть установлены зависимости проекта, доступен DVC remote и выполнена авторизация к Google Drive remote, если данные или артефакты нужно подтягивать через `dvc pull`.

Что получится после успешного запуска

- обновленные data/processed/linear и data/processed/tree датасеты;
- обновленные models/*.joblib;
- обновленные reports/modeling/*_metrics.json и *_best_params.json;
- актуальный dvc.lock после запуска DVC-стадий.