

DVC в проекте

Give Me Some Credit - краткая проектная документация. Сформировано: 10.07.2026.

Назначение

DVC используется как слой воспроизводимости для данных, признаков, моделей и метрик. В проекте зафиксированы сырьевые CSV-файлы, последовательность подготовки данных, сборка двух наборов признаков и обучение пяти семейств моделей.

Где находится

Файл или папка	Роль
dvc.yaml	Описание всех стадий пайплайна и их команд.
dvc.lock	Зафиксированные версии входов и выходов после последнего успешного запуска.
data/raw/*.csv.dvc	DVC-метаданные для исходных файлов Kaggle: train, test, sampleEntry.
.dvc/config	Настроен remote gdrive_remote на Google Drive.
reports/modeling/*_metrics.json	DVC metrics для обученных моделей, cache=false.

Пайплайн

Stage	Основной вход	Основной выход
common-prepare-train-data	data/raw/cs-training.csv	data/interim/train_prepared.csv
common-prepare-test-data	data/raw/cs-test.csv	data/interim/test_prepared.csv
build-feature-engineering-datasets	data/interim/*.csv	data/processed/linear/*.csv; data/processed/tree/*.csv
train-logistic-regression	data/processed/linear/train.csv	models/logistic_regression.joblib; reports/modeling/logistic_regression_*.json
train-decision-tree	data/processed/tree/train.csv	models/decision_tree.joblib; reports/modeling/decision_tree_*.json
train-xgboost	data/processed/tree/train.csv	models/xgboost.joblib; reports/modeling/xgboost_*.json
train-catboost	data/processed/tree/train.csv	models/catboost.joblib; reports/modeling/catboost_*.json
train-random-forest	data/processed/tree/train.csv	models/random_forest.joblib; reports/modeling/random_forest_*.json

Артефакты

DVC-пайплайн создает три уровня данных:

- data/interim - очищенные и переименованные train/test таблицы.
- data/processed/linear - датасеты с признаками для логистической регрессии.
- data/processed/tree - датасеты с признаками для деревьев, XGBoost, CatBoost и Random Forest.

Модели сохраняются в models/*.joblib, параметры и метрики - в reports/modeling/*.json.

Как запускать

```
poetry install
poetry run dvc pull
poetry run dvc repro
poetry run dvc repro train-xgboost
poetry run dvc metrics show
```

Полный `dvc repro` пересобирает только изменившиеся стадии. Для точечного запуска можно указать конкретный stage, например `train-xgboost` или `build-feature-engineering-datasets`.